Francisco Soler, Andrés Guerrero, Julio Alejandro Gómez, Mariana Villabona Martínez.

**Proyecto Transversal**

**Gestión de Proyectos de Investigación y Ciencia Abierta**

## 1. Introducción y Contexto

**Artículo.** El artículo "Estimating a Social Cost of Carbon for Global Energy Consumption" busca generar una estimación empírica del costo social del carbono (SCC) monetario asociado al consumo energético global. La métrica busca capturar los daños económicos futuros provocados por emisiones adicionales de una tonelada de CO2.

Para cumplir el objetivo anterior, el artículo adopta un enfoque "bottom-up" con un modelo Data-Driven Spatial Climate Impact Model (DSCIM); contrario al tradicional Integradet Assesment Model (AIMs) utilizado para este tipo de prácticas. Los autores utilizan una base de datos global que combina información sobre el consumo energético, el clima, los ingresos y la población para 146 países, entre 1971 y 2010. Luego estiman econométricamente cómo responde el consumo energético a variaciones en la temperatura, teniendo en cuenta diferencias de ingresos y clima entre países.

Los resultados muestran que el calentamiento global aumentará el consumo de electricidad (principalmente por mayor uso de aire acondicionado) pero reducirá el consumo de combustibles usados para calefacción. A nivel agregado global, estas fuerzas se compensan parcialmente. Por ello, el estudio encuentra que el impacto neto del cambio climático sobre el gasto energético global podría ser pequeño e incluso negativo, con estimaciones del SCC energético entre −3 y −1 dólares por tonelada de $CO_2$, dependiendo del descuento aplicado. Sin embargo, destaca que el efecto es heterogéneo y que en economías emergente que presenten una mayor exposición a climas con altas temperaturas, el efecto podría tener repercusiones negativas.

**Objetivo de la reproducción.** El objetivo es replicar las primeras etapas del proceso empírico del artículo, específicamente Step 1 y Step 2 del repositorio del proyecto[1], que corresponden a la construcción del Dataset y la estimación econométrica de la relación entre temperatura y consumo energético.

En el Step 1, el propósito es reconstruir el Dataset utilizado en el estudio combinando múltiples fuentes de información global. Este paso incluye la limpieza y armonización de datos de consumo energético provenientes de la International Energy Agency (IEA), datos climáticos históricos del Global Meteorological Forcing Dataset (GMFD) y variables socioeconómicas como ingreso per cápita y población. Posteriormente, estos datos se integran en un panel país-año que permite analizar la relación entre clima y consumo energético.

En el Step 2, el objetivo es estimar econométricamente cómo las variaciones en la temperatura afectan el consumo energético. Para ello se utilizan regresiones que relacionan cambios en temperatura con cambios en consumo de electricidad y otros combustibles, considerando heterogeneidad según niveles de ingreso y condiciones climáticas. Estas estimaciones permiten recuperar la relación empírica fundamental entre temperatura y demanda energética que posteriormente es utilizada en el artículo para proyectar impactos del cambio climático en el largo plazo.

La razón por la cual se replicaron estos procesos es porque la construcción de la base de datos, además del primer conjunto de resultados, representaban gran parte del proceso de generación y análisis de datos del Paper original. Además, este proceso implicaba el uso de gran parte de las lecciones vistas en clase, como el uso de la terminal para configurar el ambiente de trabajo, el correr un proceso casi automatizado que corría todos los códigos y también hacía uso de Stata, Python y R. Por otra parte, las regresiones son el core del ejercicio, por lo que eran la forma de comprobar que el ejercicio de replicación generaba los resultados antes encontrados.

**Recursos utilizados.** Para la reproducción se utilizan los recursos proporcionados por los autores en el repositorio público del proyecto, el cual contiene parte del código, documentación y estructuras de datos necesarias para replicar el análisis.

[1] Repositorio disponible en el siguiente link

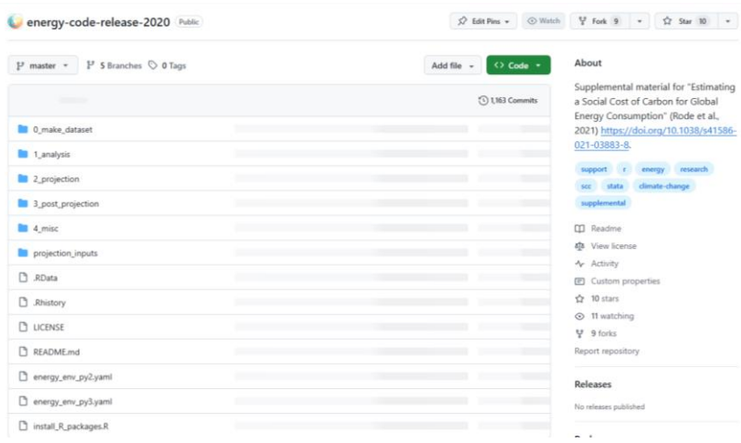


*Fig.1 Repositorio original de "Estimating a Social Cost of Carbon for Global Energy Consumption" (Rode er al, 2021)*

El repositorio incluye principalmente scripts de procesamiento de datos y estimación econométrica que permiten ejecutar los pasos iniciales del análisis. En particular, el código disponible permite reconstruir el dataset final utilizado en las regresiones y ejecutar los modelos econométricos que estiman la relación entre temperatura y consumo energético.

Los datos utilizados provienen de varias fuentes. El consumo energético se obtiene del World Energy Balances de la International Energy Agency (IEA), mientras que los datos climáticos provienen del Global Meteorological Forcing Dataset (GMFD), que ofrece información diaria de temperatura y precipitación a una resolución espacial de 0.25 grados. Además, se utilizan datos de ingreso per cápita y población, provenientes del Banco Mundial e integrados en las bases de la IEA. Los autores referencian a Zenodo[2] que contiene todos los datos a utilizar y que deben descargarse para la replicación.

Aunque la información era en general accesible, la configuración del entorno computacional representó un desafío para algunos miembros del equipo, como se detallará más adelante. Además, el uso de Stata, R y Python exigió especificar las versiones de cada software en el entorno. Si bien la mayoría de las instrucciones de replicación eran claras, es posible que no se hayan documentado ciertos pasos adicionales necesarios para garantizar una reproducción completa del análisis.

## 2. Metodología de Reproducción

**Estrategia implementada.** Como se mencionó anteriormente, la estrategia de reproducción se basó en replicar las primeras etapas del flujo de trabajo computacional del estudio, correspondientes a la construcción del dataset y a la estimación econométrica de la relación entre temperatura y consumo energético. Estos pasos constituyen la base empírica del artículo, ya que permiten reconstruir el conjunto de datos utilizado por los autores y estimar la relación fundamental entre variables climáticas y consumo energético.

El proceso de reproducción se organizó en tres fases principales. En primer lugar, se generó un fork sobre el repositorio original del Paper y este fue compartido con todos los miembros del equipo. Posteriormente, y en el computador de cada integrante, se configuró el entorno computacional necesario para ejecutar el código del repositorio y sus dependencias. En segundo lugar, se reconstruyó el conjunto de datos mediante la limpieza, transformación y combinación de múltiples fuentes de información, incluyendo datos de consumo energético, variables climáticas y datos socioeconómicos. Finalmente, se ejecutaron los procedimientos econométricos que estiman la relación entre temperatura y consumo energético, generando las regresiones y resultados que constituyen la base del análisis del estudio.

Este enfoque permitió replicar las etapas iniciales del pipeline de investigación, manteniendo la estructura modular del repositorio original y siguiendo la lógica de reproducibilidad planteada por los autores.

**Entorno computacional.** Para la reproducción se utilizó el entorno computacional propuesto en el repositorio original del estudio que sigue el siguiente flujo de trabajo.

[2] DOI del Zenodo asociado al proyecto original: https://doi.org/10.5281/zenodo.5099834

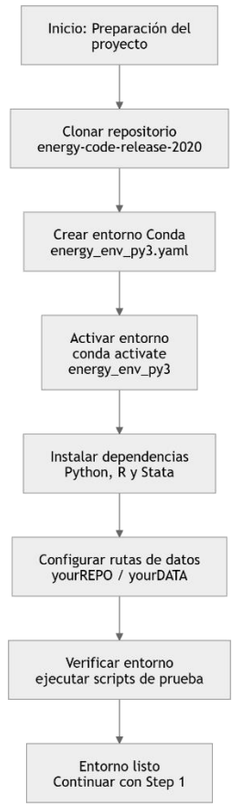


*Fig.2 Pipeline inicial: configuración del entorno computacional, siguiendo modelo sugerido por los autores*

Como se observa en la figura 2, en primer lugar se clonó el repositorio del proyecto desde GitHub y se configuró el entorno de trabajo utilizando Conda. El entorno fue creado a partir del archivo de configuración proporcionado en el repositorio (energy_env_py3.yaml) y posteriormente activado para ejecutar los scripts del proyecto. Este entorno incluye las librerías necesarias para el procesamiento de datos y para la ejecución de los scripts en Python. Además, el flujo de trabajo requiere la disponibilidad de Python, R y Stata, ya que el repositorio combina herramientas de diferentes lenguajes para distintas etapas del procesamiento y análisis de datos.

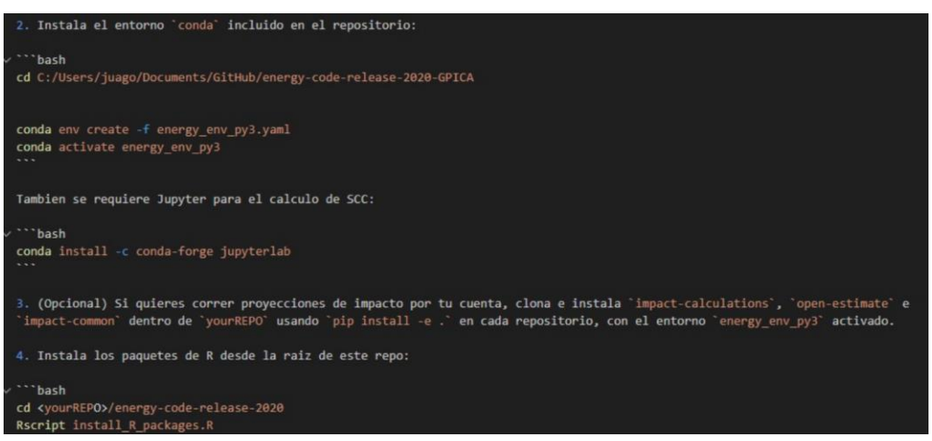

```
2. Instala el entorno `conda` incluido en el repositorio:

```bash
cd C:/Users/juago/Documents/GitHub/energy-code-release-2020-GPICA


conda env create -f energy_env_py3.yaml
conda activate energy_env_py3
```

Tambien se requiere Jupyter para el calculo de SCC:

```bash
conda install -c conda-forge jupyterlab
```

3. (Opcional) Si quieres correr proyecciones de impacto por tu cuenta, clona e instala `impact-calculations`, `open-estimate` e `impact-common` dentro de `yourREPO` usando `pip install -e .` en cada repositorio, con el entorno `energy_env_py3` activado.

4. Instala los paquetes de R desde la raiz de este repo:

```bash
cd <yourREPO>/energy-code-release-2020
Rscript install_R_packages.R
```
```

*Fig.3 Configuración del entorno de trabajo utilizando Conda.*

Una vez configurado el entorno, se establecieron las rutas de trabajo para los datos y los resultados del proyecto, garantizando que los scripts pudieran acceder correctamente a todos los archivos necesarios. No obstante, estas rutas debían definirse como variables de entorno del sistema, lo que generó dificultades en algunos de los computadores. En particular, ciertos nombres de variables clave ya estaban siendo utilizados por otros programas, especialmente aquellos relacionados con SQL, lo que impidió una configuración óptima y uniforme entre los dispositivos del equipo.

Finalmente, se realizaron pruebas iniciales para verificar que las dependencias y configuraciones funcionaran correctamente antes de ejecutar las etapas de procesamiento y análisis.

**Procesamiento y configuración de datos: Descripción de las transformaciones y construcciones realizadas.** La figura 4 muestra la estructura básica del estudio, construida vía mermaid, para poder comprender la organización completa del repositorio y entender el pipeline completo.

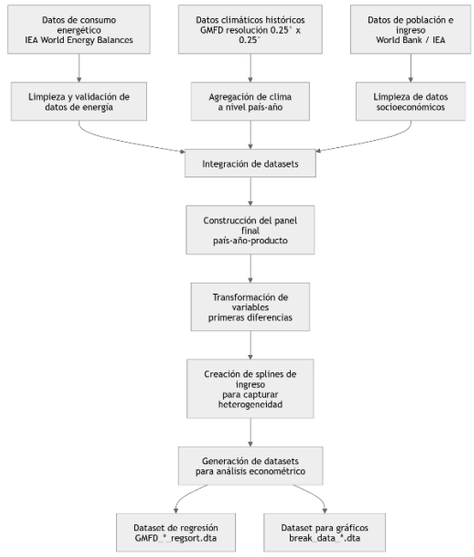


*Fig.4 Estructura original del repositorio*

Cómo puede observarse anteriormente, el procesamiento consiste en generar un panel año-producto, que posteriormente es procesado o modificado para capturar comportamientos relevantes para el estudio y así generar los datasets. Sin embargo, al evaluar con más detalle cómo se generaría este proceso, las instrucciones nos remiten a un proceso más detallado[3]. A continuación, se detalla el flujo de trabajo y los outputs esperados.

*Fig.5 Proceso detallado de reproducción de datos y análisis*

En primer lugar, *script 1_construct_dataset_from_raw_inputs.do* limpia y combina los datos de energía, clima, población e ingreso, produciendo un dataset intermedio denominado IEA_merged_long_GMFD.dta.

[3] Disponible en la carpeta /0_make_dataset del repositorio.

Posteriormente, *script 2_construct_regression_ready_data.do* transforma este dataset intermedio en datasets listos para regresiones. En esta etapa se eliminan observaciones con problemas de reporte, se emparejan los datos climáticos con los productos energéticos y se construyen variables clave del análisis, incluyendo splines de ingreso, clasificaciones por deciles de ingreso y variables en primeras diferencias. El resultado son los datasets GMFD_TINV_clim_regsort.dta (modelo principal) y GMFD_TINV_clim_EX_regsort.dta (modelo alternativo).

Finalmente, se ejecutan scripts adicionales para validar y visualizar los datos. *script 3_unit_root_test_and_plot.do* realiza pruebas de raíz unitaria que justifican el uso de primeras diferencias, mientras que *4_plot_ITA_other_energy_regimes_timeseries.R* genera una serie temporal ilustrativa utilizada en el apéndice del artículo.

Una particularidad importante es que no es posible recrear ni modificar el dataset original, dado que las bases de datos principales son de carácter privado. Por esta razón, los autores incluyeron en el archivo disponible en Zenodo únicamente los datos necesarios para la reproducción parcial del análisis, junto con los scripts empleados en el procesamiento. Sin embargo, estos scripts no pueden ejecutarse de manera completa, ya que no existe acceso a las fuentes de datos originales que alimentan el procesamiento descrito.

El dataset suministrado por los autores en el repositorio en Zenodo constituye la base para todos los pasos de la ejecución consiguiente, en el cual se estiman diferentes modelos econométricos que permiten recuperar la relación empírica entre temperatura y consumo energético.

**Análisis Econométrico: Replicación del análisis econométrico**

Para comprender la estructura preliminar, se realizó el mismo ejercicio que en el proceso anterior. A partir de la descripción general se mapeo el entendimiento básico de lo requerido para las estimaciones.

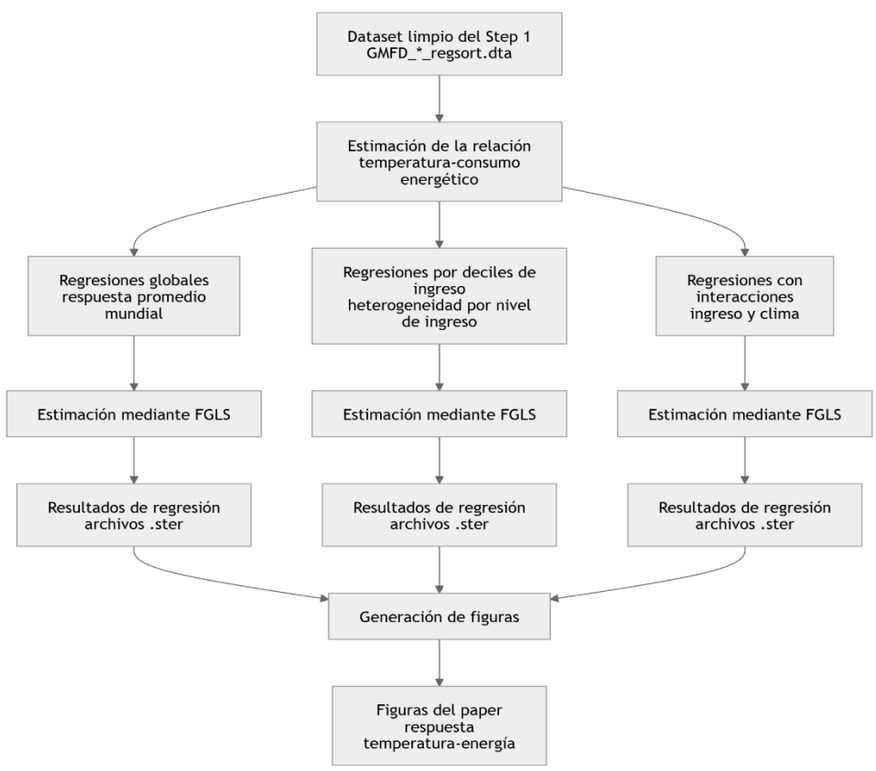


Sin embargo, al indagar sobre la carpeta del repositorio asociado a esta etapa / **1_analysis** se encontró que la complejidad del proceso era más alta, como se muestra a continuación.

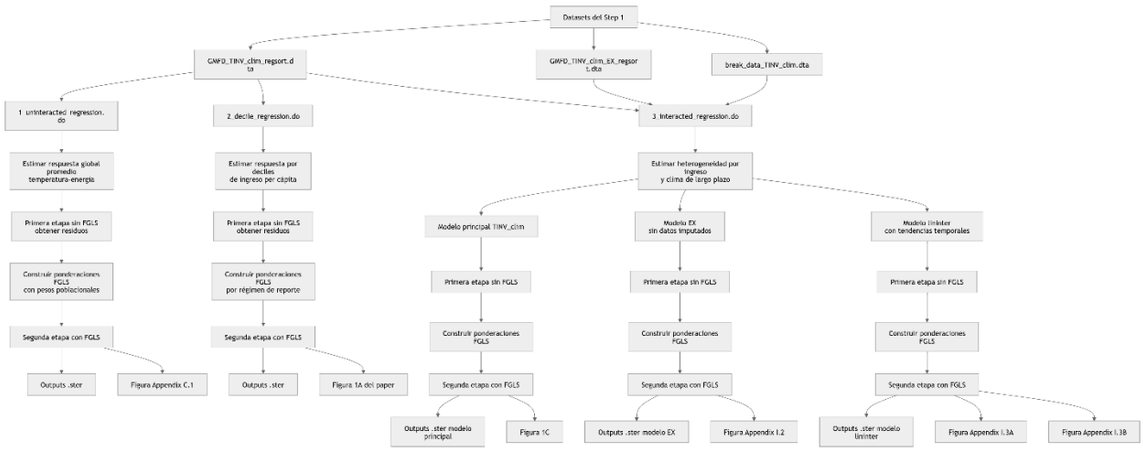


Esta etapa se implementa mediante tres tipos de análisis que permiten caracterizar cómo responde el consumo energético a variaciones en la temperatura bajo diferentes supuestos de heterogeneidad. Nuevamente, encontramos en el repositorio un 1_analysis.sh que corría sistemáticamente los procesos.

En primer lugar, el script 1_uninteracted_regression.do estima la respuesta promedio global entre temperatura y consumo energético, sin considerar heterogeneidad entre países. Este análisis produce estimaciones del efecto promedio de la temperatura sobre el consumo energético y genera la figura correspondiente al resultado agregado presentado en el apéndice del artículo.

En segundo lugar, el script 2_decile_regression.do estima la relación entre temperatura y consumo energético para distintos deciles de ingreso per cápita, lo que permite analizar cómo varía la sensibilidad energética al clima dependiendo del nivel de desarrollo económico de los países.

Finalmente, el script 3_interacted_regression.do estima modelos con interacciones entre temperatura, ingreso y clima de largo plazo, con el objetivo de capturar heterogeneidad más compleja en la relación energía-temperatura. Estos modelos incluyen tres especificaciones: el modelo principal, una versión que excluye datos imputados y un modelo que incorpora tendencias temporales.

Todas las regresiones utilizan un procedimiento de Feasible Generalized Least Squares (FGLS) para corregir problemas de heterocedasticidad asociados a diferencias en la calidad de los datos entre regímenes de reporte. Este procedimiento consiste en estimar primero un modelo base para obtener los residuos y luego utilizar la varianza de estos residuos para construir ponderaciones que se aplican en una segunda etapa de estimación.

Los resultados de estas regresiones se almacenan como archivos de salida (.ster) y se utilizan para generar las figuras del artículo que ilustran la relación estimada entre temperatura y consumo energético.

## 3. Resultados y Análisis (30%)

**Comparación de resultados.** Para evaluar la reproducibilidad del estudio, se compararon los coeficientes estimados en la replicación con aquellos reportados en el artículo original. La estimación se realizó utilizando el mismo conjunto de datos provisto por el repositorio del proyecto y ejecutando los scripts de análisis econométrico-incluidos en el repositorio.

Los resultados obtenidos muestran una alta coincidencia con los resultados originales. En particular, los coeficientes asociados a las variables climáticas principales, como la temperatura media (FD_temp1_GMFD) y su término cuadrático (FD_temp2_GMFD), presentan valores prácticamente idénticos a los reportados en el estudio original. Esto sugiere que la replicación del modelo econométrico fue exitosa.

Asimismo, las variables relacionadas con los grados-día de calefacción (HDD) y refrigeración (CDD) muestran magnitudes y signos consistentes con los resultados del artículo, lo que confirma la robustez de los efectos estimados entre temperatura y consumo energético.

**Análisis de discrepancias.** No se identificaron discrepancias significativas entre los coeficientes replicados y los resultados reportados en el artículo original. Las pequeñas diferencias observadas en algunos coeficientes pueden atribuirse a factores menores como diferencias en versiones de software, redondeo numérico o variaciones en la configuración del entorno computacional.

**Verificación y validación.** La validación de los resultados se realizó mediante la ejecución directa de los scripts proporcionados en el repositorio del estudio. En particular, se cargaron los resultados econométricos almacenados en archivos .ster y se verificaron los coeficientes estimados utilizando comandos de Stata como matrix list e(b).

Adicionalmente, se inspeccionó la estructura del dataset utilizado en la regresión (GMFD_TINV_clim_regsort.dta), confirmando que las variables utilizadas en el modelo coincidían con aquellas definidas en el código de análisis. Este procedimiento permitió garantizar que los resultados obtenidos correspondieran efectivamente a la estimación del modelo original.

| Variable | Resultado original | Resultado replicado | Diferencia |
|---|---|---|---|
| Temperatura (FD_temp1_GMFD) | 0.00013 | 0.000129 | ~0 |
| Temperatura$^2$ (FD_temp2_GMFD) | -6.9e-06 | -6.9e-06 | ~0 |
| HDD (FD_hdd20) | 4.7e-10 | 4.7e-10 | ~0 |
| CDD (FD_cdd20) | 3.3e-07 | 3.3e-07 | ~0 |
| Interacción ingreso | 0.2138 | 0.2138 | ~0 |

- Comparación de resultados
- Comparación entre los resultados obtenidos en el estudio original y los resultados reproducidos durante el proyecto.
- Análisis de discrepancias
- Explicación de posibles diferencias encontradas entre los resultados originales y los obtenidos en la reproducción.
- Verificación y validación
- Descripción de los métodos utilizados para verificar la precisión y validez de los resultados reproducidos.
- Evaluación del proceso
- Reflexión sobre la gestión del proyecto, incluyendo aspectos relacionados con la automatización del flujo de trabajo, la colaboración entre los miembros del equipo y las decisiones tomadas durante el desarrollo del proyecto.
- Lecciones aprendidas
- Principales aprendizajes obtenidos durante el proceso de reproducción, especialmente en relación con la reproducibilidad científica.
- Recomendaciones
- Sugerencias para mejorar la reproducibilidad del estudio original o facilitar futuras replicaciones.

## 4. Reflexión y conclusiones

- Evaluación del proceso: Reflexión sobre la gestión del proyecto, automatización, trabajo colaborativo y sobre el flujo de trabajo.
- Se espera que reflejen desafíos y dificultades que han tenido.
- Lecciones aprendidas: Aprendizajes clave sobre reproducibilidad científica. Recomendaciones: Sugerencias para mejorar la reproducibilidad del estudio original.

## 5. Apéndices

Rode, A., Carleton, T., Delgado, M., Greenstone, M., Houser, T., Hsiang, S., Hultgren, A., Jina, A., Kopp, R. E., McCusker, K. E., Nath, I., Rising, J., & Yuan, J. (2021). *Estimating a social cost of carbon for global energy consumption*. **Nature, 598**(7880), 308–314. https://doi.org/10.1038/s41586-021-03883-8

https://github.com/mvillabonam/energy-code-release-2020-GPICA

https://quire.io/w/energy-code-release-2020-GPICA/68?filter=all